数值分析与人工智能综合实验报告

基于 Adam 的卷积神经网络训练：数值稳定性、超参数敏感性与梯度误差分析

摘要

本实验以 Adam 优化算法训练小型卷积神经网络（CNN）为研究对象，将数值分析中的迭代法稳定性、收敛性、条件数与有限差分误差分析，与人工智能中的图像分类训练过程结合起来。实验包含三部分：其一，在以对角二次型构造的病态优化问题上，验证梯度下降（GD）的步长稳定域、条件数对收敛速度的影响，以及 Adam 的尺度不变性；其二，用中心差商与自动微分对比，分析神经网络梯度计算中的截断误差与舍入误差；其三，在手写数字数据集上，以三个随机种子重复 Adam 与动量 SGD 的对照实验，并系统扫描学习率 α、一阶矩系数 β_1、二阶矩系数 β_2 和稳定项 ϵ。结果表明：GD 的稳定域与理论阈值 $0 < \alpha < 2/L$ 一致；Adam 对目标函数整体缩放近似不变，但并非无条件稳定，学习率过大时会出现剧烈震荡甚至退化为随机猜测；在本实验的小型 CNN 上，$\alpha = 10^{-2}$ 的 Adam 取得最佳测试准确率 0.9840 ± 0.0017，而 $\alpha = 5 \times 10^{-2}$ 与 $\alpha = 10^{-1}$ 分别出现高方差和失效；β_1 过大、β_2 过小均会降低性能，ϵ 在 FP32 精度下取默认值 10^{-8} 已足够。中心差商的最优步长约为 5.6×10^{-5}，与“截断误差 $O(h^2)$ 与舍入误差 $O(\varepsilon/h)$ 折中”的理论预测相符。

关键词：数值优化；Adam；卷积神经网络；数值稳定性；超参数敏感性；有限差分；自动微分

1 问题背景

1.1 人工智能中的训练问题

卷积神经网络（CNN）已成为图像分类、目标检测和医学影像分析等任务的核心模型之一。CNN 的训练本质上是一个高维非凸优化问题：给定训练集 $\{(x_i, y_i)\}_{i=1}^{N}$，网络参数为 θ，经验风险为

$$L(\theta) = \frac{1}{N} \sum_{i=1}^{N} \ell\big(f_\theta(x_i), y_i\big), \tag{1}$$

其中 ℓ 为交叉熵损失，f_θ 为网络输出。训练通过反向传播计算 $\nabla_\theta L$，再由优化算法迭代更新 θ。在实际训练中，学习率过大可能导致损失振荡或发散，学习率过小则收敛缓慢；不同参数的梯度尺度差异很大，统一步长难以同时适配所有坐标。这些现象都可以从数值分析的角度加以解释。

1.2 数值分析视角

从数值分析看，训练算法是一个求解非线性方程 $\nabla L(\theta) = 0$ 的迭代法。梯度下降可视为梯度流

$$\dot{\theta} = -\nabla L(\theta) \tag{2}$$

的显式 Euler 离散：

$$\theta_{k+1} = \theta_k - \alpha \nabla L(\theta_k). \tag{3}$$

因此，步长 α 的选取、迭代矩阵的谱半径、问题的条件数、浮点舍入误差等概念，直接决定了训练是否稳定、收敛多快。Adam（Adaptive Moment Estimation）在 GD 的基础上引入梯度的一阶、二阶指数滑动平均，对每个坐标构造自适应步长，因而在实践中对梯度尺度不敏感，被广泛用于 CNN、Transformer 等模型的训练。

1.3 研究问题与贡献

本实验围绕以下问题展开：

(1) 在可解析分析的二次型问题上，GD 的步长稳定域是否与理论阈值一致？条件数如何影响收敛速度？Adam 的尺度不变性表现在哪里？

(2) 神经网络梯度由自动微分给出，其数值精度如何？中心差商的截断误差与舍入误差如何折中？

(3) 在真实 CNN 训练中，Adam 的学习率、β_1、β_2、ϵ 如何影响收敛速度、数值稳定性和泛化性能？它与动量 SGD 有何差异？

本文的贡献在于：用一个可控的二次型实验建立“理论—现象”的对应关系；用有限差分实验定量展示梯度计算中的两类误差；再用三随机种子的 CNN 实验给出超参数敏感性的统计结果。三部分共同构成“数值分析 + 人工智能”的完整实验链条。

2 核心算法

2.1 CNN 与交叉熵损失

实验采用一个小型 CNN：输入为 8×8 灰度图像，依次经过

$$\begin{aligned} &\mathrm{Conv}(1 \to 8, 3 \times 3) \to \mathrm{ReLU} \to \mathrm{MaxPool}(2) \\ &\to \mathrm{Conv}(8 \to 16, 3 \times 3) \to \mathrm{ReLU} \\ &\to \mathrm{Flatten} \to \mathrm{FC}(256 \to 32) \to \mathrm{ReLU} \to \mathrm{FC}(32 \to 10). \end{aligned}$$

网络输出 10 维 logits，经 softmax 得到类别概率。交叉熵损失为

$$\ell(\hat{y}, y) = -\log \hat{y}_y, \qquad \hat{y} = \mathrm{softmax}(z), \tag{4}$$

其中 z 为 logits，y 为真实类别。反向传播（等价于反向模式自动微分）给出 $\nabla_\theta L$。

2.2 Adam 优化算法

设第 t 步的小批量梯度为 $g_t = \nabla_\theta L_t(\theta_{t-1})$。Adam 维护一阶矩估计 m_t 与二阶矩估计 v_t：

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t, \tag{5}$$

$$v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2, \tag{6}$$

并作偏差校正：

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}, \qquad \hat{v}_t = \frac{v_t}{1-\beta_2^t}. \tag{7}$$

参数更新为

$$\theta_t = \theta_{t-1} - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}. \tag{8}$$

其中 α 为学习率，$\beta_1, \beta_2 \in [0,1)$ 控制历史信息的遗忘速度，$\epsilon > 0$ 防止分母过小。默认取 $\alpha = 10^{-3}$、$\beta_1 = 0.9$、$\beta_2 = 0.999$、$\epsilon = 10^{-8}$。算法流程见算法 1。

Algorithm 1 Adam 优化算法

Require: 初始参数 θ_0，学习率 α，矩估计系数 β_1, β_2，稳定项 ϵ

$m_0 \leftarrow 0, \quad v_0 \leftarrow 0$
for $t = 1, 2, \ldots, T$ **do**
  $g_t \leftarrow \nabla_\theta L_t(\theta_{t-1})$
  $m_t \leftarrow \beta_1 m_{t-1} + (1-\beta_1) g_t$
  $v_t \leftarrow \beta_2 v_{t-1} + (1-\beta_2) g_t^2$
  $\hat{m}_t \leftarrow m_t / (1-\beta_1^t)$
  $\hat{v}_t \leftarrow v_t / (1-\beta_2^t)$
  $\theta_t \leftarrow \theta_{t-1} - \alpha\, \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon)$
end for
return θ_T

2.3 对照算法

为评价 Adam 的相对表现，实验使用带动量的 SGD 作为对照：

$$u_t = \beta u_{t-1} + g_t, \qquad \theta_t = \theta_{t-1} - \alpha u_t, \tag{9}$$

其中动量系数 $\beta = 0.9$，学习率 $\alpha = 0.02$。在二次型实验中还使用普通 GD，以便与解析结果对照。

2.4 中心差商

设一元函数 f 充分光滑。中心差商

$$D_h f(x) = \frac{f(x+h) - f(x-h)}{2h} \tag{10}$$

逼近 $f'(x)$。由 Taylor 展开，

$$f(x+h) - f(x-h) = 2hf'(x) + \frac{h^3}{3}f'''(\xi), \tag{11}$$

故截断误差为 $O(h^2)$。另一方面，$f(x \pm h)$ 的浮点求值带有相对误差 ε，差商中的舍入误差约为 $O(\varepsilon|f|/h)$。两类误差的折中决定了最优步长，详见第 3.5 节。

3 理论分析

3.1 梯度流、显式 Euler 与步长稳定域

考虑二次型

$$L(\theta) = \frac{1}{2}\theta^T A\theta, \qquad A = A^T \succ 0, \tag{12}$$

其中 A 的特征值为 $0 < \lambda_{\min} = \lambda_1 \le \cdots \le \lambda_d = \lambda_{\max}$。GD 迭代为

$$\theta_{k+1} = (I - \alpha A)\theta_k, \tag{13}$$

故

$$\theta_k = (I - \alpha A)^k \theta_0. \tag{14}$$

迭代收敛当且仅当谱半径

$$\rho(I - \alpha A) = \max_{1 \le i \le d} |1 - \alpha\lambda_i| < 1, \tag{15}$$

即

$$0 < \alpha < \frac{2}{\lambda_{\max}} = \frac{2}{L}. \tag{16}$$

当 α 接近上界时，对应最大特征值的分量快速衰减，但对应最小特征值的分量衰减很慢；收敛速度由

$$\rho = \max\big(|1 - \alpha\lambda_{\min}|,\ |1 - \alpha\lambda_{\max}|\big) \tag{17}$$

控制。条件数 $\kappa = \lambda_{\max}/\lambda_{\min}$ 越大，收敛越慢。这解释了病态问题中 GD 的“锯齿”与停滞现象。

3.2 Adam 的偏差校正与尺度不变性

假设梯度在短期内近似平稳，即 $\mathbb{E}[g_t] \approx g$。由 m_t 的展开

$$m_t = (1 - \beta_1)\sum_{i=1}^{t} \beta_1^{t-i} g_i \tag{18}$$

可得

$$\mathbb{E}[m_t] = (1 - \beta_1^t)g. \tag{19}$$

因此 $\hat{m}_t = m_t/(1-\beta_1^t)$ 是 g 的无偏估计；同理，$\hat{v}_t$ 是 $\mathbb{E}[g^2]$ 的无偏估计。偏差校正的作用在训练初期尤其明显：若不做校正，m_t 与 v_t 都偏向零，更新量会被系统性低估。

若梯度整体放大 c 倍（$g \mapsto cg$，$c > 0$），则 $m_t \mapsto cm_t$、$v_t \mapsto c^2 v_t$，于是

$$\frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\epsilon} \longmapsto \frac{c\hat{m}_t}{c\sqrt{\hat{v}_t}+\epsilon}. \tag{20}$$

当 ϵ 相对于 $c\sqrt{\hat{v}_t}$ 可忽略时，更新方向与归一化幅度近似不变，这就是 Adam 的尺度不变性。它使 Adam 对损失函数整体缩放、不同参数梯度尺度差异具有较强鲁棒性。但 ϵ 破坏了严格的尺度不变性：ϵ 越大，尺度不变性越弱，更新越接近“未归一化”的梯度法。

此外，在 $\beta_1 = \beta_2 = \beta$ 的特殊情形下，由 Jensen 不等式有 $|\hat{m}_{t,i}| \le \sqrt{\hat{v}_{t,i}}$，因此每个坐标的更新量满足

$$|\Delta\theta_{t,i}| \le \alpha. \tag{21}$$

一般情况下 $\beta_1 \neq \beta_2$，该比值可能略大于 1，但 ϵ 仍为分母提供下界，使单步更新不会因 v_t 过小而爆炸。这是 Adam 数值稳定性的重要来源。

3.3 非凸情形下的收敛性

CNN 的损失函数通常非凸，且不满足全局强凸性，因此不能直接套用二次型的收敛结论。对 L-光滑且梯度有界的非凸目标，Kingma 与 Ba 证明了：取递减步长 $\alpha_t = \alpha/\sqrt{t}$ 时，Adam 满足

$$\min_{1\le t\le T} \mathbb{E}\big[\|\nabla L(\theta_t)\|^2\big] = \mathcal{O}\left(\frac{1}{\sqrt{T}}\right). \tag{22}$$

这一结果说明 Adam 在适当步长下可以保证梯度范数趋于零（到一阶稳定点），但它依赖光滑性、梯度有界等假设，且只给出最坏情况下的次线性速率。Reddi 等人进一步指出，原始 Adam 在某些凸问题上可能不收敛，原因是 β_1, β_2 的相互作用会使有效步长不单调；AMSGrad 通过维护二阶矩的 running maximum 修复了这一问题。因此，Adam 的“经验上很稳”与“理论上无条件收敛”是两回事，实验中的超参数选择仍然重要。

3.4 数值稳定性分析

Adam 的更新分母为 $\sqrt{\hat{v}_t}+\epsilon$。当某个坐标的梯度长期很小，$\hat{v}_t$ 可能接近零；若没有 ϵ，更新量 $\alpha\hat{m}_t/\sqrt{\hat{v}_t}$ 可能非常大。ϵ 提供了分母下界，保证

$$\left|\frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\epsilon}\right| \le \frac{|\hat{m}_t|}{\epsilon}, \tag{23}$$

从而避免除零和溢出。但 ϵ 过大也会带来偏差：它相当于把自适应更新“拉回”到普通梯度更新，降低有效步长。在 FP32 下，机器精度约为 1.19×10^{-7}，默认 $\epsilon = 10^{-8}$ 与 $\sqrt{\hat{v}_t}$ 的量级相比通常很小；而在 FP16 或混合精度训练中，ϵ 需要相应放大，否则 $\hat{v}_t$ 的下溢会使分母失去意义。

学习率 α 是最关键的稳定性参数。由式 (8)，α 直接控制全局步长；过大的 α 会使参数在极小值附近来回跳动，损失震荡甚至发散。β_1 控制一阶矩的记忆长度：β_1 越大，

方向越平滑，但对梯度方向变化的响应越滞后；β_2 控制二阶矩的记忆长度：β_2 越大，自适应分母越平滑，但面对非平稳梯度时可能“过期”，导致步长失配。实际训练中应监控梯度范数、损失曲线和参数更新范数，以便及早发现数值异常。

3.5 有限差分的截断误差与舍入误差

对式 (10)，由 Taylor 展开，

$$D_h f(x) = f'(x) + \frac{h^2}{6} f'''(\xi) + O(h^4), \tag{24}$$

故截断误差约为 $\frac{h^2}{6}|f'''(\xi)|$。另一方面，计算 $f(x \pm h)$ 时的相对舍入误差为 ε，绝对误差约为 $\varepsilon|f|$；两个相近的数相减会损失有效数字，差商的舍入误差约为

$$\frac{\varepsilon|f|}{2h}. \tag{25}$$

因此总误差可建模为

$$E(h) \approx Ch^2 + \frac{\varepsilon|f|}{2h}. \tag{26}$$

令 $E'(h) = 0$ 得

$$h^* \approx \left(\frac{\varepsilon|f|}{4C}\right)^{1/3}. \tag{27}$$

对双精度 $\varepsilon \approx 2.2 \times 10^{-16}$，若 C 与 $|f|$ 同量级，则 h^* 约为 10^{-5} 量级。这预测了误差—步长曲线呈“U 形”：h 太大时截断误差占主导，h 太小时舍入误差占主导。第 5.2 节的实验将验证这一预测。

3.6 超参数作用与实验假设

综合以上分析，提出如下实验假设：

H1. 学习率 α 存在一个稳定上界；超过该上界后，训练损失出现震荡或发散。

H2. β_1 过大（接近 1）会因动量滞后而减慢收敛；β_1 适中时收敛较快。

H3. β_2 过小会使自适应分母对当前梯度过于敏感，导致训练不稳定或性能下降；β_2 接近 1 时更平滑，但过大可能对非平稳梯度响应不足。

H4. ϵ 在 FP32 下取默认值附近时影响较小；明显增大 ϵ 会降低有效步长，减慢收敛。

H5. Adam 对目标函数整体缩放近似不变；GD 则不具此性质，步长需随曲率缩放。

4 编程实践

4.1 实验环境

实验在 Windows 11 上完成，使用 conda 环境 `jup`：

- Python 3.11；
- PyTorch 2.14.1（CPU 版）；
- NumPy 2.4.4、pandas 3.0.2、Matplotlib 3.10.8、scikit-learn 1.7.1。

所有随机种子固定，数据划分、模型初始化和小批量顺序均可复现。完整实验脚本为`代码/报告实验脚本.py`，图表与数据表分别保存在`实验结果/图表/报告实验/`和`实验结果/数据表/报告实验/`目录。

4.2 数据与模型

使用 scikit-learn 自带的 Digits 数据集：共 1797 张 8×8 灰度手写数字图像，10 个类别。像素值除以 16 归一化到 $[0, 1]$。按分层抽样划分为训练集、验证集、测试集，比例为 70%/15%/15%，对应 1257/270/270 个样本。

CNN 结构如第 2.1 节所述，参数总量为

$$80 + 1168 + 8224 + 330 = 9802.$$

训练使用交叉熵损失、批量大小 64、18 个 epoch，不使用权重衰减、Dropout 或数据增强，以突出优化算法本身的影响。

4.3 实验设计

实验分为三部分。

(1) 二次型实验。取 $d = 20$，$A = \mathrm{diag}(\lambda_1, \ldots, \lambda_d)$，特征值在对数尺度上从 1 到 100 均匀分布，条件数 $\kappa = 100$。初始点 $\theta_0 = (1, \ldots, 1)^T$，迭代 1000 步。比较 GD 在 $\alpha = 10^{-3}, 10^{-2}, 1.9 \times 10^{-2}, 2.1 \times 10^{-2}, 5 \times 10^{-2}$ 下的表现；比较 GD、动量法与 Adam 的收敛速度；并考察目标函数放大 10^3 倍时 Adam 与 GD 的差异。

(2) 梯度有限差分检验。在双精度下取一个小批量，用自动微分计算第一层卷积权重的梯度，再对梯度绝对值最大的 8 个坐标用中心差商式 (10) 计算近似值。步长 h 取 10^{-8} 到 1 之间的 33 个对数等距点，记录相对误差的中位数。

(3) CNN 训练实验。固定数据划分，使用 3 个随机种子（2026、2027、2028）重复每个配置；对每个种子，模型初始化和小批量顺序相同，从而保证不同超参数配置之间的对照是受控的。共扫描 12 个配置：

- 基线：动量 SGD（$\alpha = 0.02$，动量 0.9）与默认 Adam；
- 学习率：$\alpha = 10^{-4}, 10^{-3}, 10^{-2}, 5 \times 10^{-2}, 10^{-1}$；
- 一阶矩：$\beta_1 = 0.5, 0.9, 0.99$；
- 二阶矩：$\beta_2 = 0.9, 0.999, 0.9999$；
- 稳定项：$\epsilon = 10^{-8}, 10^{-5}, 10^{-3}$。

每个 epoch 记录训练损失、验证损失、验证准确率和平均梯度范数；训练结束后在测试集上计算测试损失与准确率。所有指标报告三个种子的均值与标准差。

4.4 评价指标与可复现性

主要指标为测试准确率与测试损失，辅助指标为最终验证准确率和最终平均梯度范数。梯度范数定义为

$$\|\nabla_\theta L\|_2 = \Big(\sum_j \|\nabla_{\theta_j} L\|_2^2\Big)^{1/2}, \tag{28}$$

在每个小批量更新前计算，再对一个 epoch 内的批次取平均。该指标用于观察梯度爆炸、梯度消失以及不同优化器的更新尺度。为保证可复现性，脚本在每次训练前调用 `set_seed(seed)`，并为训练数据加载器使用固定种子的 `torch.Generator`。

5 数值结果

5.1 二次型实验：步长稳定域与尺度不变性

二次型实验的结果如图 1 和表 1 所示。理论稳定域为 $0 < \alpha < 2/\lambda_{\max} = 0.02$。实验中 $\alpha = 1.9 \times 10^{-2}$ 稳定收敛，而 $\alpha = 2.1 \times 10^{-2}$ 与 $\alpha = 5 \times 10^{-2}$ 均发散，与理论阈值一致。$\alpha = 10^{-3}$ 虽然稳定，但 1000 步后 f/f_0 仍约为 7.59×10^{-4}，收敛很慢；$\alpha = 10^{-2}$ 与 1.9×10^{-2} 分别在 391 步和 206 步内达到 10^{-6}。这说明步长不能一味取小：在稳定域内适当增大 α 可以显著加速收敛。

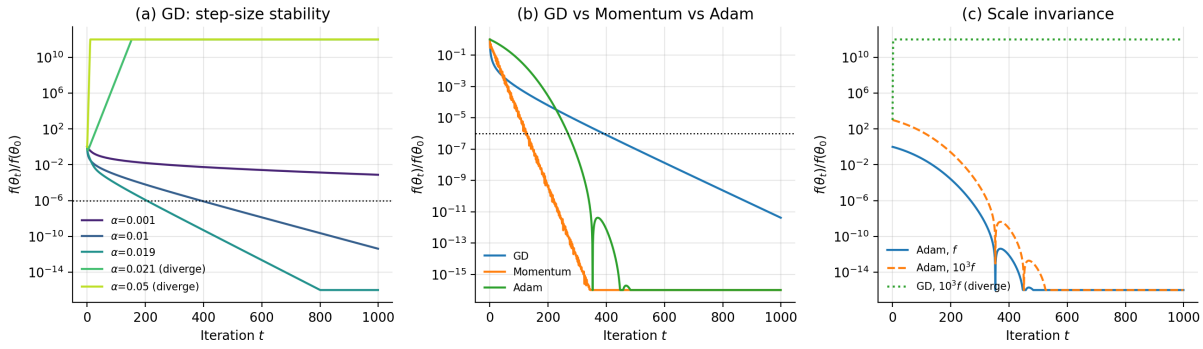


图 1: 二次型优化实验。(a) GD 在不同步长下的收敛/发散行为，虚线为 10^{-6} 容差；(b) GD、动量法与 Adam 的对比；(c) Adam 的尺度不变性：目标函数放大 10^3 倍后 Adam 的收敛曲线几乎不变，而 GD 发散。

表 1: 二次型实验的收敛表现（$d = 20$，$\kappa = 100$，1000 次迭代）

方法	设置	是否发散	达到 10^{-6} 的迭代数	最终 f/f_0
GD	$\alpha = 10^{-3}$	否	—	7.59×10^{-4}
GD	$\alpha = 10^{-2}$	否	391	4.15×10^{-12}
GD	$\alpha = 1.9 \times 10^{-2}$	否	206	4.91×10^{-20}
GD	$\alpha = 2.1 \times 10^{-2}$	是	—	1.09×10^{82}
GD	$\alpha = 5 \times 10^{-2}$	是	—	∞
Momentum	$\alpha = 10^{-2},\ \beta = 0.9$	否	125	9.05×10^{-47}
Adam	$\alpha = 10^{-2}$	否	270	7.00×10^{-43}

图 1(b) 显示，动量法在 125 步内达到 10^{-6}，是三种方法中最快的；Adam 用 270 步，略慢于动量法，但在初期下降很快，随后出现明显的非单调振荡。这一现象与 Adam 的自适应归一化有关：在病态二次型上，不同坐标的有效步长被拉平，最小特征值方向上的更新相对过大，因而产生过冲。它提醒我们，Adam 的“快速初期下降”并不等于“单调收敛”。

图 1(c) 验证了尺度不变性：将目标函数放大 10^3 倍后，Adam 的 f/f_0 曲线与原始问题几乎重合；而 GD 在同样的 $\alpha = 10^{-2}$ 下发散，因为有效曲率放大了 10^3 倍，违反了稳定域条件。这是 Adam 在实际深度学习中受欢迎的重要原因之一。

5.2 梯度有限差分检验

梯度检验结果如图 2 所示。误差—步长曲线呈明显的 U 形：当 $h = 10^{-8}$ 时，中位数相对误差约为 2.48×10^{-6}，舍入误差占主导；随着 h 增大，误差迅速下降，在 $h \approx 5.6 \times 10^{-5}$ 处达到最小值 3.75×10^{-10}；此后截断误差占主导，$h = 1$ 时相对误差约为 0.542。最优步长的量级与第 3.5 节的理论预测 $h^* \sim 10^{-5}$ 一致。

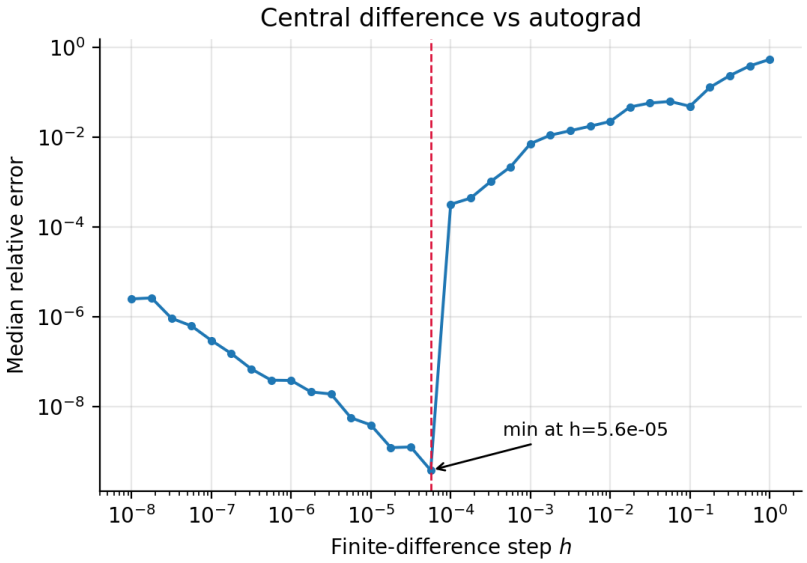


图 2: 中心差商与自动微分的相对误差随步长 h 的变化。红色虚线标出中位数误差最小的步长 $h \approx 5.6 \times 10^{-5}$。

该实验有两点意义。第一，它验证了 PyTorch 自动微分实现的正确性：在合适的步长下，中心差商与自动微分的相对误差可达 10^{-10} 量级。第二，它直观展示了数值微分中“截断误差—舍入误差”的经典折中：步长并非越小越好，过小的 h 会因浮点相减损失有效数字而使误差反弹。这一结论对深度学习中的梯度检查、有限差分灵敏度分析等实践具有直接指导意义。

5.3 CNN 基线对比：Adam 与动量 SGD

图 3 给出 Adam 与动量 SGD 在三个种子上的均值曲线，表 2 给出全部配置的测试指标。基线结果如下：

- 动量 SGD：测试损失 0.1130 ± 0.0135，测试准确率 0.9630 ± 0.0060；
- 默认 Adam：测试损失 0.1762 ± 0.0129，测试准确率 0.9481 ± 0.0030。

Adam 在前 5 个 epoch 的验证损失下降更快、验证准确率上升更快，体现了自适应步长的初期加速作用；但在 18 个 epoch 结束时，动量 SGD 的验证损失和测试损失都更低，最终测试准确率也略高。图 3(c) 显示，SGD 的梯度范数在训练中期出现峰值后持续下降，而 Adam 的梯度范数保持在较高水平（约 1.7），说明 Adam 的归一化更新并未让梯度本身变小，而是改变了参数更新的尺度。

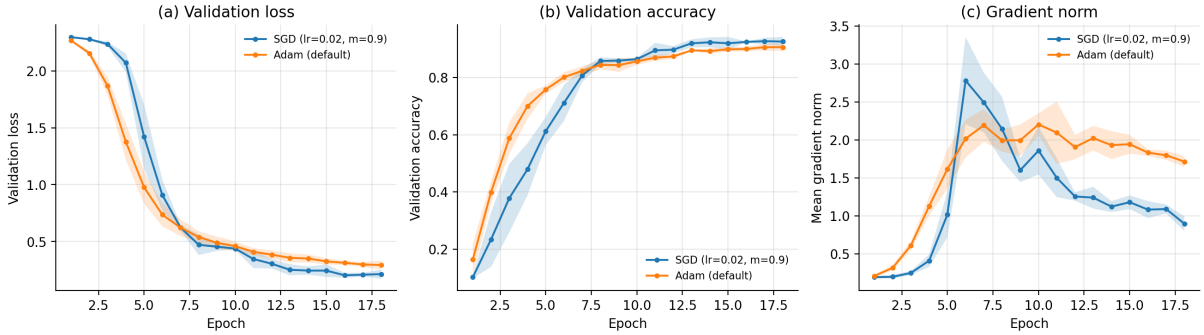


图 3: Adam 与动量 SGD 的基线对比（三个种子的均值，阴影为标准差）。(a) 验证损失；(b) 验证准确率；(c) 平均梯度范数。

5.4 超参数敏感性

5.4.1 学习率 α

学习率扫描结果如图 4 所示。$\alpha = 10^{-4}$ 时训练几乎停滞，18 个 epoch 后测试准确率仅为 0.5691 ± 0.0501；$\alpha = 10^{-3}$（默认）恢复到 0.9481 ± 0.0030；$\alpha = 10^{-2}$ 取得最佳测试准确率 0.9840 ± 0.0017，且曲线最平滑。继续增大到 $\alpha = 5 \times 10^{-2}$ 时，三个种子的结果出现巨大分化：测试准确率均值 0.6642、标准差 0.3990，其中一个种子退化为随机猜测（0.10）；$\alpha = 10^{-1}$ 时三个种子全部停留在 0.10 左右，训练完全失效。这与第 3.4 节的分析一致：学习率超过稳定范围后，参数更新在极小值附近剧烈震荡，甚至把网络推入 ReLU 大面积失活的退化区域。

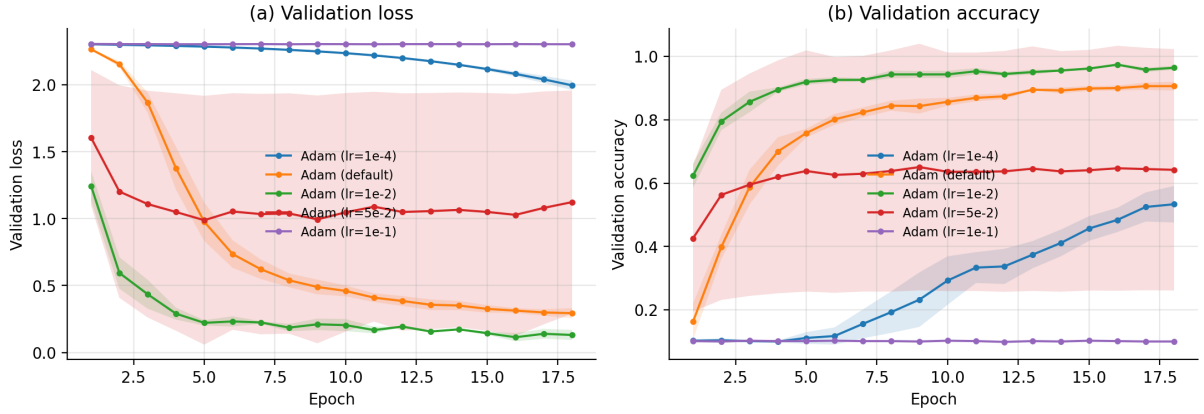


图 4: 学习率对 Adam 训练的影响（三个种子的均值与标准差）。(a) 验证损失；(b) 验证准确率。$\alpha = 10^{-2}$ 收敛最快且最稳定；$\alpha = 5 \times 10^{-2}$ 出现高方差，$\alpha = 10^{-1}$ 失效。

5.4.2 一阶矩系数 β_1 与二阶矩系数 β_2

图 5 给出 β_1 与 β_2 的扫描结果。$\beta_1 = 0.5$ 时验证损失下降最快，最终测试准确率 0.9494 ± 0.0076，与默认值 0.9481 ± 0.0030 接近；$\beta_1 = 0.99$ 时动量记忆过长，验证损失下降明显变慢，最终测试准确率降至 0.9136 ± 0.0167。这说明 β_1 过大时，历史梯度方向会滞后于当前损失面的变化，导致收敛变慢。

$\beta_2 = 0.9$ 时测试准确率降至 0.9235 ± 0.0076，验证损失也明显高于默认值；$\beta_2 = 0.9999$ 时测试准确率 0.9469 ± 0.0017，与默认值 0.999 接近。β_2 过小意味着二阶矩对当前梯度过于敏感，自适应分母波动大，等效步长不稳定；β_2 过大则对非平稳梯度的响应变慢，但在本实验的短训练中影响不显著。

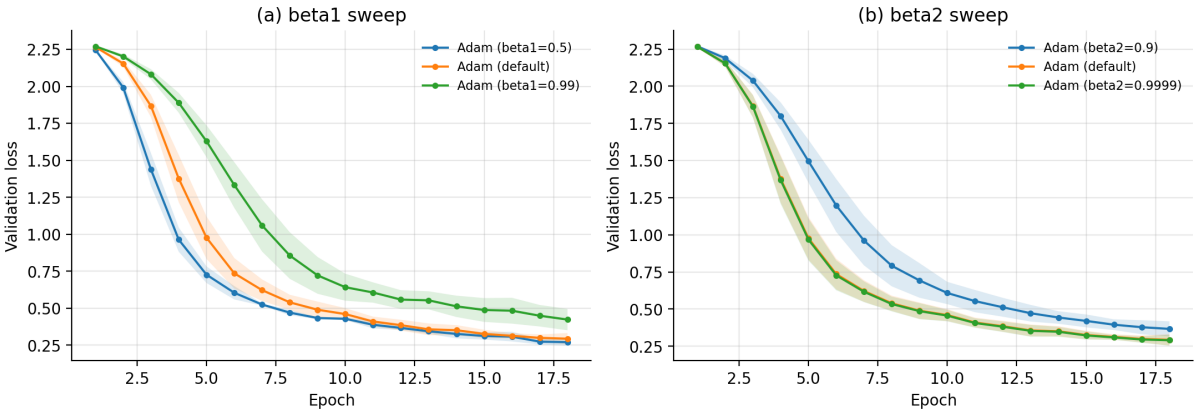


图 5: 矩估计系数的影响（验证损失，三个种子的均值与标准差）。(a) β_1 扫描：$\beta_1 = 0.99$ 明显减慢收敛；(b) β_2 扫描：$\beta_2 = 0.9$ 性能下降，$\beta_2 = 0.9999$ 与默认值接近。

5.4.3 稳定项 ϵ

图 6 显示，$\epsilon = 10^{-5}$ 的曲线与默认 $\epsilon = 10^{-8}$ 几乎重合，最终测试准确率 0.9469 ± 0.0035，差异在统计误差范围内；$\epsilon = 10^{-3}$ 则使验证损失下降变慢，最终测试准确率降至 0.9333 ± 0.0080。这与第 3.4 节的分析一致：在 FP32 下，默认 ϵ 相对于 $\sqrt{\hat{v}_t}$ 很小，增大 ϵ 会削弱自适应归一化的效果，使有效步长变小。需要注意的是，在 FP16 或低精度训练中，ϵ 的选择会更加关键。

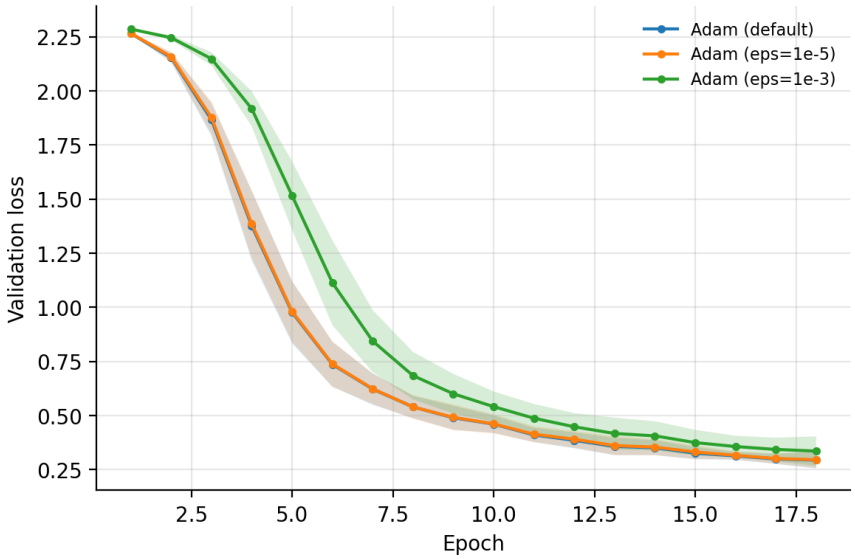


图 6: 稳定项 ϵ 对验证损失的影响（三个种子的均值与标准差）。$\epsilon = 10^{-3}$ 明显减慢收敛；$\epsilon = 10^{-5}$ 与默认值几乎一致。

表 2: CNN 训练实验汇总（三个种子的均值 ± 标准差；测试集 270 个样本）

配置	测试损失	测试准确率	最终验证准确率	最终梯度范数
SGD ($\alpha = 0.02, m = 0.9$)	0.1130 ± 0.0135	0.9630 ± 0.0060	0.9259 ± 0.0160	0.8980 ± 0.0951
Adam（默认）	0.1762 ± 0.0129	0.9481 ± 0.0030	0.9062 ± 0.0140	1.7160 ± 0.0696
Adam ($\alpha = 10^{-4}$)	1.9768 ± 0.0385	0.5691 ± 0.0501	0.5333 ± 0.0577	0.6594 ± 0.0589
Adam ($\alpha = 10^{-2}$)	0.0537 ± 0.0182	0.9840 ± 0.0017	0.9642 ± 0.0063	0.2235 ± 0.0842
Adam ($\alpha = 5 \times 10^{-2}$)	0.9527 ± 0.9569	0.6642 ± 0.3990	0.6420 ± 0.3810	0.6396 ± 0.3697
Adam ($\alpha = 10^{-1}$)	2.3035 ± 0.0006	0.1025 ± 0.0017	0.1000 ± 0.0000	0.1272 ± 0.0047
Adam ($\beta_1 = 0.5$)	0.1661 ± 0.0208	0.9494 ± 0.0076	0.9099 ± 0.0143	1.6552 ± 0.0517
Adam ($\beta_1 = 0.99$)	0.2400 ± 0.0291	0.9136 ± 0.0167	0.8827 ± 0.0076	2.8074 ± 0.2395
Adam ($\beta_2 = 0.9$)	0.2402 ± 0.0089	0.9235 ± 0.0076	0.8877 ± 0.0092	2.1408 ± 0.1425
Adam ($\beta_2 = 0.9999$)	0.1739 ± 0.0135	0.9469 ± 0.0017	0.9074 ± 0.0157	1.7016 ± 0.0708
Adam ($\epsilon = 10^{-5}$)	0.1788 ± 0.0133	0.9469 ± 0.0035	0.9086 ± 0.0126	1.7213 ± 0.0531
Adam ($\epsilon = 10^{-3}$)	0.2136 ± 0.0125	0.9333 ± 0.0080	0.8963 ± 0.0157	1.8511 ± 0.1460

5.5 讨论

综合三部分实验，可以得到以下认识。

(1) 稳定性首先由步长决定。二次型实验给出了清晰的稳定域 $0 < \alpha < 2/\lambda_{\max}$，CNN 实验则显示 $\alpha = 5 \times 10^{-2}$ 已接近失稳边界、$\alpha = 10^{-1}$ 完全失效。尽管 CNN 的损失面非凸、无法直接套用二次型的阈值，但“存在稳定上界、过大步长导致震荡或退化”的定性结论仍然成立。

(2) Adam 的自适应性是双刃剑。尺度不变性使 Adam 对梯度整体缩放和不同坐标的尺度差异不敏感，因而在初期收敛快、调参相对容易；但自适应归一化会拉平不同方向的曲率，在病态问题上造成过冲和非单调行为（图 1(b)）。在本实验中，默认 Adam 的最终测试准确率略低于动量 SGD，而 $\alpha = 10^{-2}$ 的 Adam 又明显优于两者，说明 Adam 的性能高度依赖学习率，不能简单地说“Adam 一定优于 SGD”。

(3) β_1, β_2 主要影响收敛速度与稳定性。β_1 过大导致动量滞后，β_2 过小导致自适应分母波动；这与理论分析一致。默认值 $(0.9, 0.999)$ 在本实验的短训练中表现稳健。

(4) ϵ 在 FP32 下不是主要矛盾。$\epsilon = 10^{-8}$ 与 10^{-5} 的差异很小，而 10^{-3} 会明显降低有效步长。这个结论依赖于精度和梯度尺度，不能无条件推广到混合精度训练。

(5) 数值分析提供了可检验的解释。二次型的谱分析、Adam 的偏差校正与尺度不变性、有限差分的截断—舍入折中，都能定量预测实验现象。这种“理论—可控实验—真实任务”的链条，比单纯调参更能说明算法为什么有效、在什么条件下失效。

局限性。本实验使用较小的 Digits 数据集、单一 CNN 结构和 18 个 epoch，训练规模有限；每个配置只有 3 个随机种子，统计波动仍然存在；未使用权重衰减、Dropout、数据增强或学习率调度，因此结论主要反映优化算法本身，而非完整的深度学习工程实践。此外，Adam 的收敛性定理依赖光滑性和梯度有界等假设，CNN 的实际训练并不严格满足这些条件，理论结果应作为定性指导而非严格保证。

6 结论

本实验将数值分析与人工智能结合起来，围绕 Adam 训练 CNN 的稳定性与超参数敏感性完成了三组实验。主要结论如下：

(1) 二次型实验验证了 GD 的步长稳定域 $0 < \alpha < 2/\lambda_{\max}$；条件数 $\kappa = 100$ 使最小特征值方向收敛缓慢；动量法和 Adam 都能加速病态问题，但 Adam 可能出现非单调过冲。

(2) Adam 对目标函数整体缩放近似不变：目标放大 10^3 倍后其收敛曲线几乎不变，而 GD 在相同步长下发散。ϵ 破坏严格尺度不变性，并在分母上提供数值保护。

(3) 中心差商的误差随步长呈 U 形，最优步长约 5.6×10^{-5}，最小相对误差 3.75×10^{-10}，与截断误差 $O(h^2)$、舍入误差 $O(\varepsilon/h)$ 的折中分析一致。

(4) 在 Digits 小型 CNN 上，$\alpha = 10^{-2}$ 的 Adam 取得最佳测试准确率 0.9840 ± 0.0017；默认 Adam 为 0.9481 ± 0.0030，略低于动量 SGD 的 0.9630 ± 0.0060；$\alpha = 5 \times 10^{-2}$ 出现高方差，$\alpha = 10^{-1}$ 失效。

(5) $\beta_1 = 0.99$、$\beta_2 = 0.9$ 均降低性能；$\beta_1 = 0.5$ 与默认值接近；$\epsilon = 10^{-3}$ 减慢收敛，$\epsilon = 10^{-5}$ 与默认值差异很小。

这些结果说明：Adam 的实用性来自动量平滑与自适应归一化的结合，但其稳定性仍受学习率、矩估计系数和数值精度制约；数值分析中的谱分析、误差分析和稳定性理论，可以为深度学习优化器的选择与调参提供可检验的依据。

参考文献

[1] D. P. Kingma and J. Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*, 2015.

[2] S. J. Reddi, S. Kale, and S. Kumar. On the convergence of Adam and beyond. In *International Conference on Learning Representations (ICLR)*, 2018.

[3] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016.

[4] J. Nocedal and S. J. Wright. *Numerical Optimization*, 2nd edition. Springer, 2006.

[5] R. L. Burden and J. D. Faires. *Numerical Analysis*, 10th edition. Cengage Learning, 2016.

[6] S. Ruder. An overview of gradient descent optimization algorithms. *arXiv preprint arXiv:1609.04747*, 2016.

[7] A. Paszke, S. Gross, F. Massa, et al. PyTorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.

[8] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.